

lual, 400x

# Classificação de Imagens Médicas: Diagnóstico da Doença de Sauron

Abordagens via CNN (From Scratch) e Transfer Learning (DenseNet121)

 GABRIEL PENHA

 MACHINE LEARNING & DEEP LEARNING

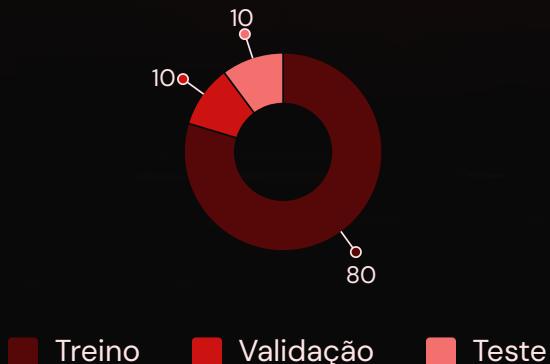
# O Desafio e o Dataset

## Parceria com ONG "Elfos Muito Legais"

Desenvolvimento de sistema automatizado para **classificação binária** de imagens médicas: células positivas versus negativas para a Doença de Sauron.

## Conjunto de Dados

- ~27.000 **imagens** microscópicas de alta resolução
- 80% para treinamento do modelo
- 10% para validação durante o treino
- 10% isolado para teste final



## Ferramentas Utilizadas

TensorFlow/Keras com aceleração em Google Colab (TPU/GPU)

# Pipeline de Dados (ETL)

**01**

## Carregamento Eficiente

Utilização de `image_dataset_from_directory` para gestão otimizada de memória, carregando imagens sob demanda.

**02**

## Normalização

Rescaling dos valores de pixel para o intervalo [0-1], essencial para convergência rápida da rede neural.

**03**

## Data Augmentation

Aplicação de transformações aleatórias para aumentar a robustez do modelo e prevenir overfitting.

### Implementação do Data Augmentation

```
data_augmentation = tf.keras.Sequential([
    layers.Rescaling(1./255),
    layers.RandomFlip("horizontal_and_vertical"),
    layers.RandomRotation(0.2),
    layers.RandomZoom(0.2),
])
```

Estas técnicas aumentam artificialmente o dataset, criando variações realistas das imagens originais.

# CNN "From Scratch"

Desenvolvimento de arquitetura customizada para aprendizado direto das características das imagens médicas.

## Modelo Simples (Inicial)

- Arquitetura com poucas camadas convolucionais
- **~5M parâmetros** treináveis
- Resultado: Overfitting rápido
- Limitação na capacidade de generalização

## Modelo Deep (Final Otimizado)

- Arquitetura profunda: 4 blocos Conv2D + MaxPooling
- **~3.4M parâmetros** (mais eficiente)
- Incorporação de **Dropout (0.5)** para regularização
- Melhor equilíbrio entre complexidade e desempenho

Model: "sequential\_2"

Layer (type)	Output Shape	Param #
sequential (Sequential)	(None, 150, 150, 3)	0
conv2d_2 (Conv2D)	(None, 148, 148, 32)	896
max_pooling2d_2 (MaxPooling2D)	(None, 74, 74, 32)	0
conv2d_3 (Conv2D)	(None, 72, 72, 64)	18,496
max_pooling2d_3 (MaxPooling2D)	(None, 36, 36, 64)	0
conv2d_4 (Conv2D)	(None, 34, 34, 128)	73,856
max_pooling2d_4 (MaxPooling2D)	(None, 17, 17, 128)	0
conv2d_5 (Conv2D)	(None, 15, 15, 128)	147,584
max_pooling2d_5 (MaxPooling2D)	(None, 7, 7, 128)	0
flatten_1 (Flatten)	(None, 6272)	0
dropout (Dropout)	(None, 6272)	0
dense_2 (Dense)	(None, 512)	3,211,776
dense_3 (Dense)	(None, 1)	513

Total params: 3,453,121 (13.17 MB)

Trainable params: 3,453,121 (13.17 MB)

Non-trainable params: 0 (0.00 B)

# Resultados da CNN From Scratch

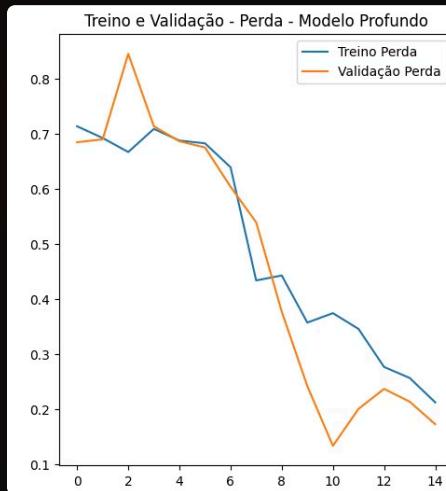
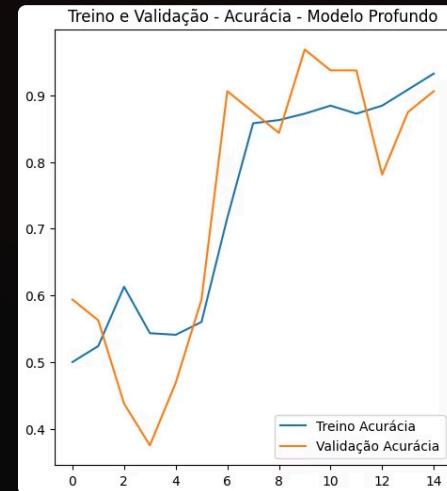


Gráfico de Loss durante o treinamento



Evolução da Accuracy por época

**96.27%**

**Acurácia no Teste**

Desempenho final após otimização da arquitetura

**3.4M**

**Parâmetros**

Modelo enxuto e eficiente

**4**

**Blocos Conv**

Profundidade da rede neural

**Conclusão:** O modelo aprendeu padrões relevantes, mas exigiu iterações na arquitetura para evitar overfitting e alcançar boa generalização.

# Transfer Learning com DenseNet121

## Arquitetura Escolhida: DenseNet121

Rede pré-treinada na ImageNet, aproveitando conhecimento de **milhões de imagens** para acelerar o aprendizado.



### Reuso Inteligente de Features

Conexões densas entre camadas permitem melhor fluxo de gradientes e features.



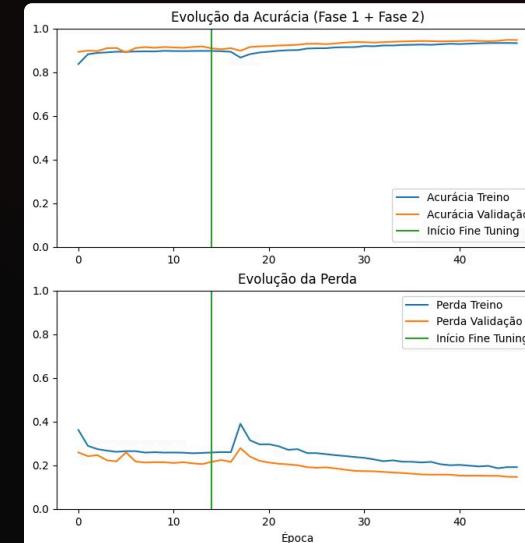
### Eficiência de Parâmetros

Arquitetura compacta que reduz redundância e melhora a eficiência computacional.



### Conhecimento Pré-existente

Modelo já treinado em ImageNet oferece base sólida de features visuais genéricas.



## ▢ Estratégia de Implementação

1. **Feature Extraction:** Base DenseNet congelada
2. **Classificador Custom:** Camadas finais adaptadas ao problema
3. **Fine-tuning:** Ajuste fino das últimas camadas

# Fine Tuning: O Diferencial

Técnica crucial para adaptar o modelo pré-treinado às especificidades das imagens médicas da Doença de Sauron.



## Descongelamento Seletivo

Liberação das **últimas 30 camadas** da DenseNet121 para adaptação ao domínio médico.



## Learning Rate Reduzido

Uso de **taxa de aprendizado baixa (1e-5)** para ajustes finos sem degradar conhecimento pré-existente.



## Treinamento Refinado

Re-treino cuidadoso permitindo que a rede aprenda características específicas do dataset médico.

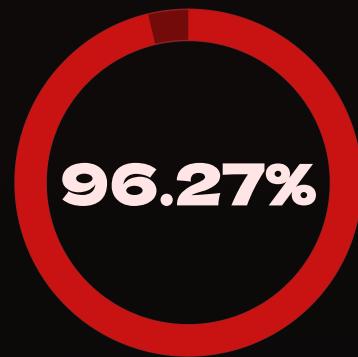
### ▢ Implementação do Fine Tuning

```
base_model.trainable = True  
fine_tune_at = len(base_model.layers) - 30  
for layer in base_model.layers[:fine_tune_at]:  
    layer.trainable = False  
model.compile(loss='binary_crossentropy',  
              optimizer = tf.keras.optimizers.RMSprop(learning_rate=0.00001), # Taxa bem pequena  
              metrics=['accuracy'])  
model.summary()
```

Este código desbloqueia apenas as camadas finais, mantendo as features genéricas intactas enquanto adapta as específicas.

# Resultados Finais e Comparação

Modelo	Acurácia (Teste)	Observação
CNN From Scratch	96.27%	Ótimo desempenho, mas sensível a hiperparâmetros
Transfer Learning (DenseNet121)	94.53%	Convergência mais lenta, estável, porém pesado



**Precisão Final**

CNN



**Ganho**

Melhoria sobre Transfer Learning



**Velocidade**

Convergência mais rápida

**Veredito:** O **CNN com Fine Tuning** é a solução ideal para o diagnóstico automatizado da Doença de Sauron pela ONG "Elfos Muito Legais".

# Conclusão e Próximos Passos

## Impacto Alcançado

- Automação do diagnóstico médico com alta precisão
- Redução de tempo de análise de imagens
- Suporte à decisão médica com confiabilidade de 96.27%
- Escalabilidade para processar milhares de exames

## Visão de Futuro

- Testar arquiteturas mais leves (MobileNet, EfficientNet)
- Deployment em dispositivos móveis para áreas remotas
- Expansão para classificação multiclasse
- Integração com sistemas hospitalares



# Obrigado!

Gabriel Penha | Machine Learning & Deep Learning

Projeto desenvolvido em parceria com a ONG "Elfos Muito Legais" para diagnóstico automatizado da Doença de Sauron

Made with **GAMMA**